

Classificação ESG por Machine Learning

Phelipe Calado de Souza Costa¹

¹Banco de Dados e IA – Centro de Estudos e Sistemas Avançados do Recife (CESAR School) – Recife – PE – Brazil
pcsc@cesar.school

Abstract. *This work presents a machine learning solution for ESG (Environmental, Social and Governance) risk classification based on a dataset of 722 publicly traded companies. A data pipeline was built using a medallion architecture (Bronze → Silver → Gold), followed by the training and comparison of three supervised models — KNN, Decision Tree, and Random Forest — with stratified cross-validation, hyperparameter optimization, and experiment tracking via MLflow. Results were delivered through an interactive Streamlit dashboard containerized with Docker, providing a supplier criticality matrix, an ESG risk map, and a KPI and ranking panel. The solution demonstrates that a structured MLOps pipeline can produce actionable and reproducible business intelligence tools for supply chain risk management.*

Keywords. *AI; Data Science; classification; regression; ESG;*

Resumo. *Este trabalho apresenta uma solução de machine learning para classificação de risco ESG (Environmental, Social and Governance) a partir de um dataset de 722 empresas de capital aberto, foi construído um pipeline de dados em arquitetura medalhão (Bronze → Silver → Gold), seguido do treinamento e comparação de três modelos supervisionados — KNN, Árvore de Decisão e Random Forest, com validação cruzada estratificada, otimização de hiperparâmetros e rastreamento via MLflow. Os resultados foram disponibilizados em um dashboard interativo em Streamlit containerizado com Docker, entregando uma matriz de criticidade de fornecedores, um mapa de riscos ESG e um painel de KPIs e ranking. A solução demonstra que um pipeline estruturado de MLOps é capaz de produzir ferramentas de inteligência de negócios acionáveis e reproduzíveis para a gestão de risco em cadeias de suprimentos.*

Palavras-chave. *IA; Ciência de Dados; classificação; regressão; ESG;*

1. Introdução

Em nossa sociedade atual, notamos um movimento no qual empresas e governos são cada vez mais cobrados por práticas responsáveis que vão além do lucro. Nesse contexto, surge o conceito de ESG (Environmental, Social and Governance), que avalia o desempenho de organizações e o seu impacto. A empresa cliente deste projeto, precisa gerir uma cadeia de fornecedores e garantir que esses parceiros estejam alinhados com os critérios ESG, tanto por exigência regulatória quanto por reputação e sustentabilidade do próprio negócio.

O problema central é dado o perfil ESG de um fornecedor, seu setor, scores e grades nas dimensões E, S e G, como classificá-lo automaticamente quanto ao seu nível de risco e

maturidade, e como prever a classificação de um novo fornecedor ainda não avaliado? Trata-se de um problema duplo: de classificação (atribuir um nível de risco: alto, médio ou baixo) e de regressão (estimar o score total esperado). A dificuldade adicional é a falta de uma base de dados consolidada e robusta do cliente, no qual nos motivou a buscar uma base externa para treinamento e criação de um protótipo, que servisse de aprendizado tanto do ponto de vista acadêmico, quanto de solução de negócio viável.

O projeto terá quatro objetivos encadeados. O primeiro é construir um pipeline de dados reproduzível em arquitetura medalhão (Bronze → Silver → Gold) que garanta rastreabilidade, limpeza e preparo dos dados para Machine Learning. O segundo é treinar e comparar modelos de classificação e regressão (KNN, Árvore de Decisão e Random Forest) com rastreamento de experimentos via MLflow, selecionando o modelo com melhor desempenho no F1-score ponderado. O terceiro é entregar três produtos analíticos para o cliente: uma Matriz de Criticidade dos fornecedores por quadrante de risco, um Mapa de Riscos ESG por setor com planos de ação associados, e um Dashboard principal com KPIs, ranking e benchmarking. O quarto e último objetivo é garantir que toda a solução seja reproduzível em qualquer ambiente via Docker, seguindo boas práticas de engenharia de software e MLOps.

2. Fundamentação Teórica

2.1. ESG e suas Métricas

ESG é um acrônimo para Environmental, Social and Governance (Ambiental, Social e Governança), e representa um conjunto de critérios usados para avaliar o quão responsável e sustentável é o comportamento de uma empresa. A dimensão Ambiental (E) procura medir o impacto da empresa no ecossistema natural, avaliando a gestão de carbono, uso de energia, geração de resíduos, uso de água e biodiversidade. A dimensão Social (S) procurar medir a qualidade das relações humanas na empresa, através da avaliação das condições de trabalho, diversidade, saúde e segurança dos funcionários, e impacto nas comunidades ao redor. A dimensão de Governança (G) procura medir como a empresa é gerida internamente, através da avaliação sobre transparência em suas práticas, estrutura do conselho, ética nos negócios e conformidade regulatória.

2.2. Machine Learning

Machine Learning - ML (Aprendizado de Máquina) é a área dentro do domínio de Inteligência Artificial com metodologias para que computadores consigam identificar padrões e assim realizar previsões e agrupamentos afim de fornecer suporte a tomada de decisões, através de um aprendizado extraído diretamente de uma base de dados, usada como referência, de forma automatizada e sem a aplicação de regras manuais explicitamente programadas. A forma na qual o aprendizado é conduzido pode ser dividido nas categorias: aprendizado supervisionado, não-supervisionado, semissupervisionado e por reforço. As tarefas mais comuns de *machine learning* são Classificação e Regressão, havendo entretanto outras, como agrupamento (*clustering*) etc.

2.2.1. Classificação

Tarefa *Machine Learning* cujo objetivo é prever a categoria que pode ser atribuída a uma instância (conjunto de atributos que caracterizam algo), dentro de um conjunto discreto (finito) de possibilidades.

2.2.2. Regressão

Tarefa *Machine Learning* cujo objetivo é prever um valor numérico relacionado a uma instância, dentro de campo contínuo.

2.2.3. Modelos de Machine Learning

Modelo de *Machine Learning* é a estrutura matemática e algorítmica que definem como o computador deve realizar o seu aprendizado para se chegar ao resultado desejado. Os modelos mais comuns e que serão abordados neste trabalho são KNN (K-Nearest Neighbors, Árvore de Decisão (Decision Tree) e Random Forest (Floresta Aleatória).

2.2.3.1. KNN (K-Nearest Neighbors)

O KNN faz a avaliação através do cálculo de distâncias no plano cartesiano para encontrar os valores mais próximos daquele que se deseja classificar ou prever (regressão). É sensível a diferença de escalas entre as variáveis, logo, requer que seja feita normalização (*StandardScaler*) nos dados numéricos antes de executar o algoritmo de KNN. As metodologias para cálculos de distâncias (funções de distância ou métricas) mais comuns de serem utilizadas são Manhattan, Euclidiana e Minkowski.

2.2.3.2. Árvore de Decisão (Decision Tree)

Faz a separação dos dados através de decisões binárias, seja através de perguntas (valores positivos ou falsos), seja através de critérios de comparação ou ordenamento (maior, menor). As separações são feitas de forma progressiva até se conseguir obter o grupo mais homogêneo possível. Por ser melhor interpretável, torna-se ideal para regras de negócio e apresentação em painel de BI. Porém, sofre tende a sofrer de *overfitting* (quando o algoritmo decora os dados em vez de aprender), que pode ser melhor controlado limitando o hiperparâmetro *max_depth* (profundidade da árvore).

2.2.3.3. Random Forest

Derivação da árvore de decisão, onde esta técnica irá gerar diversas árvores independentes e diferentes entre si. O resultado final será definido através de critérios de votação – *ensemble* (para classificação) ou média (regressão) das árvores, absorvendo assim possíveis ruídos e reduzindo o problema de *overfitting*. Deve-se utilizar hiperparâmetros como *n_estimators* (número de árvores).

2.2.4. Métodos de Validação

Os modelos de *Machine Learning* aprendem através de um conjunto de dados (*dataset*). Sendo que este conjunto de dados representa uma porção da realidade (trabalho de inferência). Assim, a qualidade deste aprendizado e a precisão das suas respostas dependem diretamente da qualidade dos dados contidos neste conjunto (valores consistentes com a realidade, dados completos e coerentes etc) e de uma representatividade de cada grupo dentro do conjunto total, que tenha tamanho suficiente de exemplos para que o modelo consiga encontrar um padrão, ou seja, em termos gerais quanto maior for o tamanho e diversidade do conjunto, melhor será para o modelo aprender.

Desta forma, sendo este um trabalho de inferência, sempre haverá um erro associado entre a amostra e a realidade da população. Além disto, deve-se garantir que o modelo usado

conseguiu realizar o seu aprendizado criando uma generalização, ou seja, uma regra que descreve determinado comportamento, ao invés de simplesmente decorar os dados - *overfitting* (problema muito comum). Se criada a generalização, o modelo consegue prever o comportamento de novos dados de forma similar a sua base original. Se o modelo decorou os dados, ele irá falhar quando apresentado novos dados.

Portanto, todo trabalho de modelagem de *Machine Learning* requer a separação do conjunto de dados em um conjunto de treino (para o modelo criar a generalização) e um de teste (para validar esta generalização). As estratégias mais comuns de divisão dos dados e validação dos modelos são Hold-out, Validação Cruzada (K-Fold) e Leave-One-Out (LOO).

2.2.4.1. Hold-out

Sendo esta a metodologia mais simples, onde é feita uma única divisão de grupos para treino e outra para teste, sendo treino >> teste e os dados que estarão dentro de cada grupo são escolhidos de forma aleatória. As frações de 70/30 ou 80/20 em geral são ideais para conjuntos de dados de tamanho tradicional ou acadêmico. No entanto, a literatura destaca que a proporção correta depende do tamanho absoluto da base de dados, que quanto maior, menor pode ser a porção de treino.

- Ponto positivo: Fácil e rápida de executar.
- Ponto negativo: Como os dados que pertencerão a cada grupo de treino e teste serão escolhidos de forma aleatória, o resultado é influenciado pelo fator “sorte”. Será utilizado o parâmetro `stratify=y` do `scikit-learn` para garantir que as proporções das classes minoritárias sejam mantidas nas duas fatias.

2.2.4.2. Validação Cruzada (Cross-Validation ou K-Fold)

A validação cruzada, usando-se comumente a sigla CV (*Cross-Validation*). É feita a divisão dos dados de treino em K partes (normalmente 3, 5 ou 10). O grupo de treino será composto por K-1 parte e o de teste na parte 1 restante. Girando o processo percorrendo todas as partes de forma que todas poderão ser de treino ou de teste em algum momento.

- Ponto positivo: Elimina a sorte e fornece o desvio padrão da sua métrica, provando a estabilidade do modelo.
- Ponto negativo: Requer maior processamento computacional e mais tempo de resolução.

Tabela 1 - Critérios de escolha para o valor K (revisão literária)

K	Características
3	Cada fold de validação tem poucos dados, risco de ter viés e uma estimativa instável
5	Equilíbrio ideal, padrão da indústria
10	Tende a ser mais preciso (mas nem sempre, devido a redução do grupo de teste). É proporcionalmente mais lento e custoso computacionalmente.

O dataset tendo 722 registros, logo a escolha de K=5 mostra-se adequado para este projeto.

2.2.4.3. Leave-One-Out (LOO):

Feito de forma similar ao K-Fold, sendo que apenas um único registro é deixado de fora para teste a cada rodada.

- Ponto positivo: Em situações em que a base de dados é muito pequena, separar algo em torno de 30% a 10% do total (usando Hold-out ou K-Fold) traria uma perda sensível de informação, de forma que este método se torne adequado por exemplo para treinar um modelo para um setor ultra-específico, com pouquíssimas empresas (menos de 50 dados por exemplo).
- Ponto negativo: Inadequado para base de dados grande, tanto devido ao peso computacional exigido, quanto e principalmente, por este modelo ser muito sensível a Outliers (que iriam gerar saltos nos resultados) e retirar apenas um registro, tende a fazer com que os conjuntos de treinamento sejam muito parecidos entre si, dificultando uma generalização.

Dataset deste projeto possui 722 registros, para 3 modelos, seriam 2166 treinamentos e ainda multiplicados pelas combinações do GridSearch. Teríamos um custo computacional muito alto para pouco benefício diante dos outros modelos disponíveis que trariam melhor eficiência. O uso deste modelo seria mais adequado para uma quantidade pequena de amostras (normalmente <50), logo, esta técnica não será utilizada neste projeto.

2.2.5. Métodos de Otimização

O processo de modelagem dos modelos de ML envolve diversos parâmetros possíveis. Na busca do melhor resultado de aprendizado e predição do modelo, deve-se encontrar quais seriam estes “melhores parâmetros”. Quando estes parâmetros não podem ser desenvolvidos ou deduzidos pelo próprio modelo, ou seja, quando na verdade o modelo depende que eles venham de uma fonte externa para realizar seu aprendizado, temos os **hiperparâmetros**.

Tabela 2 - Hiperparâmetros mais comuns por modelo.

Modelo	Hiperparâmetro	Comportamento
Geral (para todos)	random_state	Semente para sorteios aleatórios. Garante que o resultado seja reproduzível. Não afeta qualidade, só reprodutibilidade. Usa-se 42 por convenção.
	cv (no GridSearch)	Número de dobras (<i>folds</i>) na validação cruzada K-Fold. Quanto maior, tende a ser mais confiável, porém, exige mais recursos computacionais (processamento, tempo de treinamento e uso de memória). Se muito pequeno, resultado instável e menos confiável
	scoring	Usada para escolher o melhor modelo durante a busca. <i>f1_weighted</i> para classes desbalanceadas, <i>accuracy</i> para classes equilibradas.

	n_jobs	Número de núcleos do processador usados em paralelo. Não afeta resultado, só velocidade. Costuma-se usar sempre -1 (todos)
K-Nearest Neighbors (KNN)	n_neighbors (ou k)	Quantidade de vizinhos próximos que participarão da votação/média. Se baixos criam fronteiras fragmentadas e causam <i>overfitting</i> . Se altos criam fronteiras suaves, mas podem causar <i>underfitting</i> . Geralmente usam-se [3, 5, 7, 9, 11]
	metric	Métrica de Distância para calcular a distância entre pontos (vizinhança). No <i>scikit-learn</i> , padrão é <i>euclidian</i> (=2). Para =1, usa-se a distância de <i>Manhattan</i> e =3, <i>Minkowski</i> .
	weights	Se todos os vizinhos têm peso igual ou se vizinhos mais próximos têm mais influência. Se <i>uniform</i> = todos iguais. Se <i>distance</i> = os mais próximos pesam mais. O <i>distance</i> costuma ser melhor em dados reais.
	algorithm	Estrutura de dados interna para encontrar vizinhos eficientemente. Se = <i>auto</i> , o <i>sklearn</i> escolhe o melhor automaticamente. Não é relevante para o resultado, só para performance.
Árvore de Decisão	max_depth	Profundidade máxima que a árvore pode crescer. Limitar esse valor impede que a árvore faça perguntas demais até que cada folha tenha apenas um único exemplo, sendo a principal ferramenta para reduzir o <i>overfitting</i> . Geralmente usam-se [3, 5, 7, 10, <i>None</i>], começando com 5.
	min_samples_split	Número mínimo de amostras necessárias em um nó para que ele possa se dividir novamente. Geralmente usam-se [2, 5, 10, 20]. Valores maiores impedem divisões em grupos muito pequenos.
	min_samples_leaf	Número mínimo de amostras exigidas para formar uma folha (decisão final). Valores maiores forçam a árvore a generalizar mais e evitam o isolamento de instâncias individuais. Geralmente usam-se [1, 2, 4, 6]. Protege contra <i>overfitting</i> em classes raras.
	criterion / Medida de Impureza	Define a matemática usada para o melhor critério de corte para um nó através a avaliação do ganho de informação. Geralmente testa-se a <i>Entropia</i> ou o <i>Coefficiente de Gini</i> (padrão). Testar os dois raramente muda muito, sendo que entropia costuma usar mais recursos computacionais.
	max_features	Quantas features considerar em cada divisão da árvore. <i>None</i> = usa todas. <i>sqrt</i> = raiz quadrada do total (padrão para Random Forest). Para Árvore simples, deixar <i>None</i> .

Random Forest	n_estimators	Define a quantidade de árvores de decisão que irão compor a "floresta" (o comitê). Quanto maior, mais robusto, menos sujeito ao <i>overfitting</i> , porém exige mais recursos computacionais (processamento, tempo de treinamento e uso de memória). Geralmente usam-se [50, 100, 200, 300], e a partir de ~200 o ganho começa a se tornar marginal, com aumento exponencial do uso de recursos.
	max_depth	Profundidade máxima que a árvore pode crescer. Árvores ilimitadas memorizam, mas Random Forest tende a absorver as anormalidades. Geralmente usam-se [3, 5, 7, 20, <i>None</i>], podendo deixar como <i>None</i> para se testar todas as possibilidades.
	max_features	Responsável por criar diversidade de árvores. Define a quantidade máxima de características sorteadas e avaliadas na hora de criar a divisão de um nó. Valores menores reduzem o risco de memorização (aumentam a aleatoriedade e diversidade das árvores) e deixam o treinamento mais rápido. <i>sqrt</i> é o padrão para classificação e é a escolha mais comum. Testar também <i>log2</i>
	bootstrap	Configuração Booleana (Verdadeiro ou Falso) que define se cada árvore treina em uma amostra com reposição do dataset (amostragem bootstrap). <i>True</i> (padrão) é o comportamento clássico do Random Forest e garante a diversidade. Raramente usa-se <i>False</i>

Não há uma regra fechada e determinística sobre quais hiperparâmetros se usar para um determinado problema a ser resolvido. Entretanto há boas práticas e um entendimento de como eles afetam o comportamento do modelo, o que ajuda a reduzir o leque de opções. Entretanto, ainda assim, o acerto dos hiperparâmetros ainda vai envolver um processo iterativo de tentativas e erros, e para suportar este processo de uma forma estruturada, as técnicas mais comuns são Grid Search (Busca em Grade) e Random Search (Busca Aleatória).

2.2.5.1. Grid Search (Busca em Grade)

Trata-se de uma matriz com todos os hiperparâmetros que se cogita experimentar, e o algoritmo irá fazer o teste de todas as combinações possíveis entre eles. Para cada combinação, o modelo é treinado e o seu desempenho é avaliado desempenho usando Validação Cruzada (Cross-Validation).

- Ponto positivo: Tende a encontrar o melhor resultado possível em uma configuração ótima dentro da grade definida.
- Ponto negativo: Alto peso computacional exigido, que cresce exponencialmente com o aumento da quantidade de hiperparâmetros e pode gerar ineficiência de tempo tratando combinações irrelevantes.

Torna-se, portanto, a opção mais adequada quando para um reduzido espaço de busca (poucos hiperparâmetros com poucas variações) e para um dataset que não seja muito grande.

2.2.5.2. Random Search (Busca Aleatória)

Irá fazer uma inferência, através da escolha de amostras aleatórias dentro da grade de parâmetros que foi definida. Estabelece-se um limite de tentativas a serem feitas.

- Ponto positivo: Por atuar em amostras, se tem economia de tempo e recursos computacionais e ainda assim, sendo capaz de obter resultados perto do que seria o ponto ótimo. Com esta otimização, consegue-se explorar regiões amplas de hiperparâmetros economizando recursos.
- Ponto negativo: Por haver um certo nível de aleatoriedade, haverá sempre uma imprecisão entre os resultados de sua inferência com o resultado ótimo ao se avaliar toda a população.

Torna-se, portanto, a opção mais adequada quando se tem um espaço de busca grande, o que levaria muita complexidade ou consumo de recursos em comparação a Grid Search.

3. Materiais e Métodos

3.1. Metodologia e Ferramentas

3.1.1. Python e Bibliotecas Utilizadas

A linguagem Python foi adotada como base tecnológica do projeto por ser o padrão consolidado da indústria em ciência de dados, combinando vasto ecossistema de bibliotecas, legibilidade de código e integração nativa com as ferramentas de MLOps utilizadas. Todo o desenvolvimento foi realizado em Jupyter Notebooks para as etapas de exploração e modelagem, e em scripts .py para os componentes de produção do pipeline e do dashboard. As bibliotecas utilizadas e suas respectivas funções no projeto foram:

- pandas: Leitura, manipulação e transformação dos dados em todas as camadas do pipeline (Bronze, Silver e Gold);
- numpy: Operações numéricas e vetoriais de suporte;
- scikit-learn: Implementação dos modelos de machine learning (KNN, Árvore de Decisão e Random Forest), pré-processamento com StandardScaler, pipelines com Pipeline e ColumnTransformer, validação cruzada com StratifiedKFold e otimização de hiperparâmetros com GridSearchCV e RandomizedSearchCV;
- matplotlib e seaborn: Visualizações analíticas estáticas na EDA;
- plotly: Visualizações interativas no dashboard;
- joblib: Serialização e carregamento dos modelos treinados em disco para inferência no dashboard;
- hashlib: Geração do hash MD5 para verificação de integridade do dataset na ingestão;
- mlflow: Rastreamento de experimentos durante o treinamento;
- streamlit: Construção do dashboard interativo.

Todas as dependências foram declaradas no arquivo requirements.txt, garantindo a reprodutibilidade do ambiente tanto em execução local quanto via Docker.

3.1.2. MLflow

O MLflow é uma plataforma *open-source* para gerenciamento de ciclo de vida de projetos de *Machine Learning (MLOps)*.

Projetos de *Machine Learning* é comum necessitarem de inúmeras iterações de ajustes de parâmetros e tentativas e erros até se descobrir qual resultado é o de melhor desempenho.

O MLflow portanto, possui os recursos para rastrear, organizar e registrar os experimentos de forma automática e padronizada, garantindo velocidade e praticidade para elaboração de relatórios e memoriais. Possui ainda recursos de captura automática de quais algoritmos foram processados, quais os hiperparâmetros escolhidos e quais foram as métricas de erro obtidas (precisão, recall, F1-score etc).

Uma vez que o propósito deste projeto é de testar, realizar sucessivos experimentos, comparar diversos modelos, hiperparâmetros e resultados e os exibir graficamente, o seu uso, portanto, será de grande valor e deve ser feito desde o início deste projeto. Cada modelo treinado será um "run" dentro de um experimento nomeado. O MLflow salvará tudo na pasta mlruns/ do projeto.

3.1.3. Docker

O Docker é uma plataforma de containerização que empacota a aplicação, suas dependências e configurações de ambiente em uma unidade isolada e portátil chamada contêiner. No contexto deste projeto, ele resolve o problema clássico de "funciona na minha máquina". Ao containerizar a solução, qualquer pessoa com Docker instalado consegue executar o dashboard com um único comando, independentemente de sistema operacional ou configuração local. A containerização foi definida pelo Dockerfile na raiz do projeto.

3.2. Estrutura de Pastas do Projeto

A organização do repositório segue as convenções de projetos de ciência de dados orientados a produção, separando claramente dados, código, modelos e aplicação

```
/
├── data/
│   ├── bronze/      # Dados brutos ingeridos do Kaggle (data.csv + metadata.json)
│   ├── silver/      # Dados limpos e padronizados (data_silver.csv)
│   └── gold/         # Dados prontos para consumo pelo dashboard e ML (data_gold.csv)
├── notebooks/       # Jupyter Notebooks de EDA e modelagem
├── docs/            # Documentos úteis do projeto (mídias, relatórios etc)
├── src/
│   ├── ingest_data.py # Ingestão via Kaggle API com hash MD5
│   ├── silver_transform.py # Transformações da camada Silver
│   ├── build_gold.py  # Construção da camada Gold com feature engineering
│   └── translator.py  # Conexão entre dataset do modelo e linguagem do cliente
```

- └─ models/ # Modelos serializados via joblib (.pkl)
- └─ app/
- └─ Home.py # Página inicial do dashboard
- └─ pages/ # Páginas do Streamlit (Scorecards, Matriz, Mapa, Previsão)
- └─ components/ # Funções auxiliares e de visualização reutilizáveis
- └─ style/ # CSS com identidade visual do cliente
- └─ mlruns/ # Artefatos e experimentos rastreados pelo MLflow
- └─ Dockerfile
- └─ requirements.txt
- └─ README.md

3.3. Fluxograma do Projeto

A figura 1 exibe o fluxograma do projeto, ilustrando o pipeline completo desde a ingestão dos dados até a “containerização”, entrega e uso do dashboard ao cliente para análise e previsão de novas empresas.




Figura 1 - Fluxograma do projeto

3.4. Fluxograma do Processo de Machine Learning

A figura 2 exibe o fluxograma comum para o processo de modelagem assistido por mlflow. Mesma filosofia foi usada neste projeto.




Figura 2 - Fluxograma de modelagem com MLflow.

3.5. Dataset

3.5.1. Origem dos Dados

O dataset principal diz respeito a avaliação ESG de empresas globais, de capital aberto listadas na NASDAQ ou NYSE e de variados setores durante o ano de 2022. É apresentado o desempenho de cada empresa para as dimensões E (Environmental), S (Social) e G (Governance) isoladamente e geral.

A seguir, resumo sobre o dataset principal:

- Fonte: kaggle (<https://www.kaggle.com/alistairking/public-company-esg-ratings-dataset>)
- Formato: CSV
- Título: data
- Tamanho: 176KB
- Registros: 722
- Atributos: 21

Para enriquecer a quantidade de informações disponíveis, trazendo mais *features* para ajudar no aprendizado do modelo, e também criar um vínculo entre o modelo do cliente e do dataset de treino, foi criado um dataset auxiliar, com os novos atributos *revenue_2021_millions_usd* e *employees_2021* consolidados do ano de 2021, usando-se como chave para pesquisa o código único CIK dados obtidos a partir do SEC 10-K / Annual Report 2021.

A seguir, resumo sobre o dataset auxiliar:

- Fonte: Gerado a partir do SEC 10-K / Annual Report 2021
- Formato: CSV
- Título: company_size_revenue_2021
- Tamanho: 39KB
- Registros: 722
- Atributos: 4

O dataset do cliente, é o seu formulário no qual coleta e consolida informações para a avaliação ESG de seus fornecedores.

A seguir, resumo sobre o dataset do cliente:

- Formato: Excel .xlsx
- Tamanho: 12KB
- Título: Forms_Diagnostico_de_Sustentabilidade_MODELO
- Registros: 10
- Atributos: 50

3.5.2. Dicionário de Dados

A seguir, apresentam-se os atributos e descrição para cada dataset.

3.5.2.1. Dataset principal

O dataset está organizado em 4 grupos naturais e uma coluna de controle:

Tabela 3 - Grupos de colunas do dataset principal

Grupo	Colunas	Descrição
Identificação	6	Dados cadastrais da empresa
Links	2	URLs de logo e site
Scores	4	Pontuações numéricas ESG
Grades e Níveis	8	Classificações categóricas ESG
Controle	1	Data de processamento

Tabela 4 - Grupo 1: Identificação da Empresa

#	Nome da Coluna	Descrição / Significado	Tipo de Dado	Formato / Padrão	Domínio / Valores Permitidos
1	ticker	Código de negociação da empresa na bolsa de valores. Identificador único no mercado financeiro.	str	Letras maiúsculas	Ex: AAPL, GOOGL, MSFT
2	name	Nome completo oficial da empresa conforme registrado na bolsa.	str	Texto livre	Ex: Apple Inc., Google LLC
3	currency	Moeda utilizada nas negociações da empresa na bolsa.	str	Código ISO 4217 (3 letras)	Ex: USD, EUR, BRL
4	exchange	Bolsa de valores onde as ações da empresa são negociadas.	str	Texto livre / sigla	Ex: NASDAQ, NYSE, LSE
5	industry	Setor ou segmento de mercado em que a empresa atua.	str	Texto livre	Ex: Technology, Healthcare, Energy
6	cik	Central Index Key — código de registro único da empresa junto à SEC (Securities and Exchange Commission), regulador do mercado americano.	int64	Número inteiro positivo	Valores inteiros positivos atribuídos pela SEC

Tabela 5 - Grupo 2: Links

#	Nome da Coluna	Descrição / Significado	Tipo de Dado	Formato / Padrão	Domínio / Valores Permitidos
7	logo	URL da imagem do logotipo oficial da empresa.	str	URL válida (https://...)	Endereço web válido ou nulo
8	weburl	URL do site oficial da empresa.	str	URL válida (https://...)	Endereço web válido ou nulo

Tabela 6 - Grupo 3: Scores Numéricos ESG

#	Nome da Coluna	Descrição / Significado	Tipo de Dado	Formato / Padrão	Domínio / Valores Permitidos
9	environment_score	Pontuação numérica de desempenho ambiental.	int64	Número inteiro	Valores positivos — quanto maior, melhor
10	social_score	Pontuação numérica de desempenho social.	int64	Número inteiro	Valores positivos — quanto maior, melhor
11	governance_score	Pontuação numérica de governança corporativa.	int64	Número inteiro	Valores positivos — quanto maior, melhor
12	total_score	Pontuação ESG total da empresa. Composição da soma dos três scores anteriores.	int64	Número inteiro	Valores positivos — soma dos scores E, S e G

Tabela 7 - Grupo 4: Grades e Níveis ESG

#	Nome da Coluna	Descrição / Significado	Tipo de Dado	Formato / Padrão	Domínio / Valores Permitidos
13	environment_grade	Nota de desempenho ambiental	str	Código de letras repetidas, 1 a 3 dígitos	AAA, AA, A, BBB, BB, B, CCC, CC, C
14	environment_level	Classificação textual do nível ambiental	str	Texto em inglês	Excellent, High, Medium, Low

15	social_grade	Nota de desempenho social.	str	Código de letras repetidas, 1 a 3 dígitos	AAA, AA, A, BBB, BB, B, CCC, CC, C
16	social_level	Classificação textual do nível social	str	Texto em inglês	Excellent, High, Medium, Low
17	governance_grade	Nota de desempenho de governança	str	Código de letras repetidas, 1 a 3 dígitos	AAA, AA, A, BBB, BB, B, CCC, CC, C
18	governance_level	Classificação textual do nível de governança	str	Texto em inglês	Excellent, High, Medium, Low
19	total_grade	Nota ESG geral da empresa em formato de letra. Derivada do total_score.	str	Código de letras repetidas, 1 a 3 dígitos	AAA, AA, A, BBB, BB, B, CCC, CC, C
20	total_level	Classificação textual do nível ESG geral correspondente ao grade total.	str	Texto em inglês	Excellent, High, Medium, Low

Tabela 8 - Coluna de Controle

#	Nome da Coluna	Descrição / Significado	Tipo de Dado	Formato / Padrão	Domínio / Valores Permitidos
21	last_processing_date	Data em que os dados da empresa foram processados/atualizados pela última vez na fonte.	str	DD-MM-YYYY	Datas. Fora do formato ISO 8601

3.5.2.2. Dataset auxiliar

Tabela 9 - Características dataset auxiliar

#	Nome da Coluna	Descrição / Significado	Tipo / Formato / Padrão	Domínio / Valores Permitidos
---	----------------	-------------------------	-------------------------	------------------------------

1	cik	Central Index Key — código de registro único da empresa junto à SEC (Securities and Exchange Commission), regulador do mercado americano.	int64 / Número inteiro positivo	São os mesmos do dataset principal. Valores inteiros positivos atribuídos pela SEC
2	ticker	Código de negociação da empresa na bolsa de valores. Identificador único no mercado financeiro.	str / Letras maiúsculas	Mesmos do dataset principal. Ex: AAPL, GOOGL, MSFT
3	revenue_2021_millions_usd	Faturamento anual bruto em Milhões de Dólares Americanos, para o ano de 2021. (Avaliação ESG durante 2022, sem faturamento consolidado para o mesmo ano).	int64 / Número inteiro	Valores positivos
4	employees_2021	Número total de funcionários, para o ano de 2021.	int64 / Número inteiro	Valores positivos

3.5.2.3. Dataset do cliente

Tabela 10 - Grupos de colunas do dataset do cliente

Grupo	Colunas	Descrição
Identificação empresa	2	Nome e CNPJ
Porte da empresa	2	Faturamento e quantidade de funcionários
Perguntas sobre práticas adotadas	28	Tem o objetivo de mapear o grau de maturidade de uma empresa em ESG. Geralmente respostas binárias "Sim" ou "Não"
Evidências	11	Verifica a confiabilidade das respostas quanto a justificativa, presença de documentos e certificados comprobatórios
Controle	11	Datas de manipulação, identificação da pessoa e sua relevância

3.5.2.4. Dataset de cadastro de novas empresas

O dataset de cadastro de novas empresas será o vínculo que fará a ligação entre o dataset do cliente e o dataset usado para predição e treino do modelo.

Tabela 11 - Características dataset de inclusão de novas empresas

#	Nome da Coluna	Descrição / Significado	Tipo / Formato Padrão	Domínio / Valores Permitidos
1	cnpj	Código único formado por números para identificação da empresa	int64/ Número inteiro positivo	Valores inteiros positivos RFB
2	sigla	Código único formado por letras de identificação da empresa	str/ Letras maiúsculas	Ex: AAPL, GOOGL, MS FT

3	nome	Nome completo oficial da empresa conforme registrado na bolsa.	str/ Texto livre	Ex: Apple Inc., Google LLC
4	perfil	Se a empresa é de um ramo tradicional ou invador	str/ Texto	Tradicional, Invadora
5	setor	Setor ou segmento de mercado em que a empresa atua.	str/ Texto livre	Ex:Tecnologia, Logística
6	faturamento	Faturamento annual bruto Reais (BRL)	int64/ Número inteiro	Valores positivos
7	tamanho	Número total de funcionários	int64/ Número inteiro	Valores positivos
8	maturidade_ambiental	Classificação textual do dimensão ambiental	str/ Texto	Excelente, Alta, Média, Baixa
9	confiabilidade_ambiental	Confiabilidade quanto as evidências apresentadas na dimensão ambiental	str/ Texto	Auditada, Não Auditada
10	maturidade_social	Classificação textual do dimensão social	str/ Texto	Excelente, Alta, Média, Baixa
11	confiabilidade_social	Confiabilidade quanto as evidências apresentadas na dimensão social	str/ Texto	Auditada, Não Auditada
12	maturidade_governanca	Classificação textual do dimensão governança	str/ Texto	Excelente, Alta, Média, Baixa

13	confiabilidade_governan ca	Confiabilidade quanto as evidências apresentadas na dimensão governança	str/ Texto	Auditada, Não Auditada
14	data_inclusao	Data em que os dados da empresa foram processados/atualizad os pela última vez na fonte.	str/ DD-MM- YYYY	Datas. Fora do formato ISO 8601

3.5.2.5. Como os dataset se conectam

O dataset principal e o auxiliar serão tratados e unidos na camada Silver.

A partir do dataset de cadastro de novas empresas será feita uma correlação entre atributos com o dataset principal e o auxiliar, permitindo a comunicação entre ambas as bases de dados e permitindo equivalência entre elas, através do script *translator.py*

O cliente, a partir do seu dataset, deve segmentar todas as 28 perguntas sobre as práticas adotadas entre as três dimensões E, S e G e em seguida atribuir para cada dimensão e de acordo com as respostas obtidas, o nível de maturidade em E, S e G, com quatro níveis possíveis: Excelente, Alto, Médio e Baixo. Esta seria a equivalência para os *x_levels* *Excellent*, *High*, *Medium* e *Low* do dataset principal.

O cliente deve segmentar todas as 11 perguntas relacionadas as evidências entre as três dimensões E, S e G e em seguida atribuir para cada dimensão se as evidências foram auditadas ou não auditadas. É nesta parte que conseguimos vincular equivalência com os *x_grade* *AAA*, *AA*, *A*, *BBB*, *BB*, *B*, *CCC*, *CC* e *C* do dataset principal. Na sessão 3.2.6 é dado maiores detalhes de que para cada classe *level* haverá duas classes *grade* possível, estabelecendo juntos um range para o *score*. É esta combinação a chave para conseguimos criar uma equivalência com o dataset principal e a forma de pensar e linguagem do cliente, de forma que ambos levem a procura da previsão do *score*.

Uma vez que as empresas fornecedoras do cliente estão no Brasil e muitas podem não estarem listadas em bolsa, criou-se o atributo “perfil” para se fazer equivalência com “exchange”, onde para “NYSE” = “Tradicional” e “NASDAQ” = “Inovadoras”, visto estas serem as características mais pronunciadas das empresas que compõem cada uma das bolsas norte americanas. Para a coluna *industry*, basta traduzir as opções para a coluna *setor*. Os demais atributos podem ter uma equivalência direta e intuitiva, sem maiores esclarecimentos.

Tabela 12 - Equivalência colunas entre datasets

Dataset novas empresas (cliente)	Dataset silver (para ML)
cnpj	cik
sigla	ticker

nome	name
perfil	exchange
setor	industry
faturamento	revenue_M
tamanho	employees
confiabilidade_ambiental	environment_grade
maturidade_ambiental	environment_level
pontuacao_ambiental	environment_score
confiabilidade_social	social_grade
maturidade_social	social_level
pontuacao_social	social_score
confiabilidade_governanca	governance_grade
maturidade_governanca	governance_level
pontuacao_governanca	governance_score
pontuacao_total	total_score
nivel_risco	risk_level
data_inclusao	last_processing_date

Tabela 13 - Equivalência avaliação ESG entre datasets

maturidade_xx	xx_level	confiabilidade_xx	xx_grade
Excelente	Excellent	Auditada	AAA
Excelente	Excellent	Não auditada	AA
Alta	High	Auditada	A
Alta	High	Não auditada	BBB
Média	Medium	Auditada	BB
Média	Medium	Não auditada	B
Baixa	Low	Auditada	CCC
Baixa	Low	Não auditada	C

Tabela 14 - Equivalência colunas setor e industry

setor	industry
Aeroespacial e Defesa	Aerospace and Defense
Companhias Aéreas	Airlines
Componentes Automotivos	Auto Components
Automóveis	Automobiles
Bancos	Banking
Bebidas	Beverages
Biotecnologia	Biotechnology
Construção Civil	Building
Químicos	Chemicals

Serviços e Suprimentos Comerciais	Commercial Services and Supplies
Comunicações	Communications
Construção	Construction
Produtos de Consumo	Consumer products
Distribuidores	Distributors
Serviços Diversificados ao Consumidor	Diversified Consumer Services
Equipamentos Elétricos	Electrical Equipment
Energia	Energy
Serviços Financeiros	Financial Services
Produtos Alimentícios	Food Products
Cuidados com a Saúde	Health Care
Saúde	Healthcare
Hotéis Restaurantes e Lazer	Hotels Restaurants and Leisure
Conglomerados Industriais	Industrial Conglomerates
Seguros	Insurance
Produtos de Lazer	Leisure Products
Ferramentas e Serviços de Ciências da Vida	Life Sciences Tools and Services
Logística e Transporte	Logistics and Transportation
Maquinário	Machinery
Marinha	Marine
Mídia	Media
Metais e Mineração	Metals and Mining
Embalagens	Packaging
Farmacêuticos	Pharmaceuticals
Serviços Profissionais	Professional Services
Imobiliário	Real Estate
Varejo	Retail
Rodovias e Ferrovias	Road and Rail
Semicondutores	Semiconductors
Tecnologia	Technology
Telecomunicações	Telecommunication
Têxteis Vestuário e Bens de Luxo	Textiles Apparel and Luxury Goods
Tabaco	Tobacco
Empresas Comerciais e Distribuidores	Trading Companies and Distributors
Utilidades	Utilities

3.6. Pré-processamento

O pipeline de transformação dos dados segue a filosofia de arquitetura medalhão. O dataset principal é extraído via script de ingestão (src\ingest_data.py) diretamente do

Kaggle , que será salvo em máquina local, primeiramente na pasta `\data\bronze`, seguindo a filosofia da arquitetura medalhão para estruturar o pipeline de dados. Foi incluído o hash MD5 (Message Digest 5) para gerar um código único de 32 caracteres (hexadecimal) para garantir a integridade da base de dados baixada. Este código garante rastreabilidade quanto a alterações na base de dado, caso venha a ocorrer qualquer adulteração no dado e mudanças futuras em sua forma ou erro no download, o código gerado será outro. A partir da primeira análise exploratória dos dados para avaliação da qualidade dos dados, identificou-se os ajustes necessários e definiu-se a seguinte sequência de transformação e tratamento para se obter os dados na camada silver, prontos para uma análise exploratória mais profunda.

3.6.1. Pipeline de Transformação de Dados

Abaixo, todas as transformações que irão ocorrer da camada Bronze para a camada Silver no dataset principal:

- 1) Carrega o dado bruto de ``data/bronze/data.csv`` e registra ``metadata.json`` com codificação Hash MD5
- 2) Descarta colunas sem utilidade para o modelo:
 - logo
 - weblink
 - currency
- 3) Reordena colunas
 - cik
 - ticker
 - name
 - exchange
 - industry
 - environment_grade
 - environment_level
 - environment_score
 - social_grade
 - social_level
 - social_score
 - governance_grade
 - governance_level
 - governance_score
 - total_grade
 - total_level
 - total_score
 - last_processing_date
- 4) Corrige inconsistências em ``industry`` : Padroniza grafias diferentes (and, & e " ")
- 5) Preenche valores nulos em ``industry``
 - Busca informações via ``yfinance`` usando o ticker
 - Fallback para ``"Unknown"``

- Últimos preenchimentos, tratados manualmente
- 6) Converte `last\_processing\_date` para `datetime`
- 7) Padroniza a coluna `cik` para o padrão da SEC (U.S. Securities and Exchange Commission), padrão zero-padding de 10 dígitos preenchidos com zeros à esquerda
- 8) Padroniza a coluna `ticker` para maiúsculas, que é o formato padrão
- 9) Simplifica a coluna `exchange` para siglas, convertendo "NEW YORK STOCK EXCHANGE, INC." para "NYSE" e "NASDAQ NMS - GLOBAL MARKET" para "NASDAQ"
- 10) Inclui as colunas `revenue\_M` e `employees` a partir respectivamente das colunas `revenue\_2021\_millions\_usd` e `employees\_2021` do dataset `data/bronze/company\_size\_revenue\_2021.csv`, usando o `cik` como chave de junção. Estas colunas serão incluídas logo após a coluna `industry`, da esquerda para a direita.
- 11) Salva o resultado em `data/silver/data\_silver.csv` registra `metadata\_silver.json` com codificação Hash MD5

Atenção em especial para o preenchimento dos valores nulos em *industry*, o script foi capaz apenas de preencher 4 ausentes, restando 9, que após pesquisa manual, foram identificados são do setor de *Financial Services* e atualizado.

Quanto ao tratamento de *outliers*, este seriam em relação ao grupo presente no dataset, entretanto, todos estavam dentro das possibilidades reais de pontuação e ranqueamento das regras de negócios, sendo portanto, mantidos como estão.

3.6.2. Variável Alvo e Engenharia de Atributos

O objetivo primário e que irá agregar valor ao cliente, é fazer uma classificação de riscos em ESG para empresas, em três níveis: Alto, Médio e Baixo. A análise da coluna *total_level* revelou que, no nível agregado, apenas duas classes existem no dataset: High e Medium. As classes Low e Excellent aparecem somente nas dimensões isoladas (E, S ou G). Uma classificação binária seria insuficiente para a Matriz de Criticidade do cliente, que exige pelo menos três grupos de risco.

Conforme verificado na EDA, notou-se que há um padrão que segmenta o `score` para as dimensões isoladas, em intervalos fixos de 200 pontos entre classes de level e de 100 pontos para classes de grade.

Pode-se então intuir que a tabela geral de score, para cada dimensão isolada, teria a seguinte estrutura:

Tabela 15 - Comportamento do score em função do level e grade

<i>level</i>	<i>score range</i>	<i>grade</i>	<i>score range</i>
excellent	600–800	AAA	700–800
		AA	600–699
high	400–599	A	500–599
		BBB	400–499
medium	200–399	BB	300–399

		B	200–299
low	0–199	CCC	100–199
		CC C	0–99

Desta forma, combinação de *grade* + *level* apenas leva a um intervalo possível de pontuação *score*, mas não o valor exato. Empresas com mesmo *grade* e mesmo *level*, podem ter *score* diferentes. A pontuação final exata depende de um "fator misterioso", que não está claro quais atributos o influenciam e é aqui que está o valor do trabalho de *Machine Learning*. Consultar normas externas de como este cálculo é feito, fugiria do objetivo deste trabalho, pois neste caso estaríamos saindo de uma análise de *Machine Learning*, que em essência busca encontrar padrões dentro de um cenário indefinido e sem "manuais ou normas de funcionamento".

É na busca deste “fator misterioso” que será feita uma análise de quais *features* do dataset podem contribuir para que o modelo consiga encontrar um padrão e se necessário, novas *features* serão atribuídas, conforme feito através do dataset auxiliar.

Por fim, para se obter a classificação de risco em alto, médio e baixo, devemos olhar para o *total_score*, que é resultado direto das somas do *environment_score*, *social_score* e *governance_score*, logo, estas serão nossas variáveis alvo, e por serem valores numérico contínuos, para estas serão feita a tarefa de Regressão.

Entretanto, com o objetivo de enriquecer o trabalho do ponto de vista acadêmico, também será incluída tarefa de Classificação, a partir do resultado total. Entretanto, volta-se a questão inicial, a coluna *total_level* possui apenas duas classes: High e Medium, insuficiente para o modelo aprender qual seria a “Low”. Como a pontuação total é resultado da soma das pontuações em cada dimensão E,S e G, foi deduzido que o intervalo teórico do *total_level* entre 0 e 2400.

Tabela 16 - Intervalo teórico

<i>total_level</i>	<i>total_score</i>
excellent	1800-2400
high	1200-1799
medium	600-1199
low	0-599

Sendo que na prática verificou-se que no dataset temos apenas dados no intervalo entre 600 e 1536, e é somente este intervalo que pode ser considerado para o *Machine Learning*, pois em essência, o modelo só aprende a partir de exemplos, ele não intui ou deduz.

Após extensiva análise de possibilidades de intervalos, verificou-se que o mais consistente, que traria em conjunto um comportamento consistente com a realidade, um razoável balanceamento entre classes, um efetivo aprendizado de máquina e prover ganhos do ponto de vista didático e usabilidade pelo cliente, que são todos o objetivo deste trabalho, a divisão de risco seguirá a seguinte regra:

- Risco alto: *total_score* < 900
- Risco médio: 900 <= *total_score* <= 1150
- Risco baixo: *total_score* > 1150

Para detalhes da dedução destes intervalos, consultar a sAssim, para a tarefa de Classificação, criou-se a variável *risk_level* derivada do *total_score* por meio dos intervalos definidos.

Feito este ajuste, obtemos o seguinte resultado da distribuição com limiares absolutos:

Tabela 17 - Balanceamento de classes após definição dos intervalos de *total_score*

Classe (<i>risk_level</i>)	Empresas	Proporção
Baixo Risco	285	39,47%
Risco Moderado	271	37,53%
Alto Risco	166	22,99%

Em resumo, serão as seguintes variáveis alvo:

- Tarefa de Regressão:
 - *environment_score*
 - *social_score*
 - *governance_score*
- Tarefa de Classificação:
 - *risk_level* (criada a partir do *total_score*)

3.7. Análise Exploratória dos Dados (EDA)

3.7.1. Tendência Central e Dispersão dos Scores ESG

Tem como objetivo comparar a distribuição dos scores nas três dimensões ESG e no score total, identificando onde as empresas se concentram e quão heterogêneas são entre si.




Figura 3 - Tendência Central e Dispersão dos Scores ESG

- Score Ambiental:
 - Tem a maior dispersão de todos, com pontos espalhados de 200 a 700+
 - Média (405) abaixo da mediana (~480), demonstrando distribuição assimétrica à esquerda, puxada por empresas com baixa performance ambiental
 - Esta se mostra como a dimensão onde as empresas mais se diferenciam entre si
- Score Social:

- Distribuição mais concentrada e simétrica, com média e mediana bem próximas (~292 e ~300)
- Há poucos outliers extremos
- Logo, empresas tendem a convergir em performance social
- Score Governança
 - Demonstra a menor amplitude de todas as dimensões
 - Ou seja, caixa compacta com empresas com comportamento mais homogêneo em governança
 - Média (279) ligeiramente abaixo da mediana (~295)
- Score Total
 - Reflete a soma dos três, portanto, dispersão moderada
 - Média (976) abaixo da mediana (~1030), assimetria puxada pelo score ambiental
 - Outliers superiores bem visíveis, havendo empresas excepcionalmente bem avaliadas
- Conclusão: O score ambiental demonstra ser o fator principal de diferenciação entre empresas. Já a Governança é onde há mais homogeneidade. O que sugere que os modelos de classificação terão no score ambiental sua feature mais discriminante.

3.7.2. Distribuição Real vs Curva Normal Teórica

Tem como objetivo confirmar visualmente a não normalidade dos scores, complementando os resultados do teste de Shapiro-Wilk.




Figura 4 - Comparação: Distribuição Real vs Curva Normal Teórica

● Conclusão

Todas as dimensões ESG apresentam p-valor < 0.05, rejeitando a hipótese nula de normalidade em todas elas.

3.7.3. Matriz de Correlação de Spearman

Tem como objetivo medir a força e direção das relações entre as dimensões ESG, identificando quais dimensões são mais interdependentes.




Figura 5 - Análise de correlações entre dimensões

- Interpretação:

Todos os pares apresentaram correlação positiva e estatisticamente significativa (p-valor ≈ 0), confirmando que as três dimensões ESG estão interligadas.

- Ambiental $\times$ Social (rho = 0.703) => Correlação forte

- É o par mais correlacionado entre as dimensões independentes
- Demonstra-se que empresas com boas práticas ambientais tendem fortemente a ter boas práticas sociais, supõe-se que possa haver uma cultura ESG integrada

- Ambiental $\times$ Governança (rho = 0.562) => Correlação moderada

- Pode-se supor que governança é mais influenciada por pressão regulatória e estrutura societária do que por cultura ESG, o que explica a correlação menor

- Social $\times$ Governança (rho = 0.579) => Correlação moderada

- Comportamento similar ao par Ambiental $\times$ Governança
- Governança é a dimensão mais "independente" das três

- Correlações com o Total:

- Ambiental $\times$ Total (0.944): altíssima. O score ambiental é o principal determinante do score total.
- Social $\times$ Total (0.824): forte. É a segunda dimensão mais determinante
- Governança $\times$ Total (0.714): forte. Porém a menos determinante das três

3.7.4. Média dos Scores ESG por Setor

Tem como objetivo identificar quais setores lideram e quais ficam abaixo da média geral em cada dimensão ESG, gerando insumo direto para a matriz de criticidade de fornecedores.




Figura 6 - Análise da distribuição da média dos Scores ESG por Setor

- **Desempenho em total score:**
 - Setores de Utilidades, Tabaco e Conclomerado Industriais, respectivamente nas primeiras três posições.
 - Setores de Serviços de Consumo Diversos, Produtos de Lazer e Linhas aéreas, respectivamente nas últimas três posições.
- **Dimensão Ambiental:**
 - Dimensão com maior variação
 - Conforme já levantado anteriormente no gráfico de boxplot, a área ambiental possui a maior variação, onde o líder Utilidades têm score de 550, enquanto a última posição Produtos de Lazer com score de 252, mais que a metade.

3.7.5. Quartis e Outliers por Dimensão ESG

Tem como objetivo identificar empresas com comportamento anômalo em relação ao grupo, candidatas a análise aprofundada na matriz de criticidade.




Figura 7 - Análise de quartis e identificação de outliers por dimensão ESG

- Score Ambiental:
 - Nenhum outlier detectado
 - Possui a maior amplitude entre as dimensões, demonstrando haver empresas com alta e baixa performance
 - Limite inferior negativo (aprox. -200) sinalizando que o metodo IQR sozinho é insuficiente avaliar para esta dimensão
- Score Social:
 - 7 outliers superiores²
- Score Governança:
 - 3 outliers superiores
 - 1 outlier inferior²
- Score total:
 - Nenhum outlier

² CMS Energy Corp: Demonstrou ter uma performance assimétrica, sendo um outlier superior para a dimensão Social, porém, também sendo um outlier inferior na dimensão Governança

3.7.6. Kruskal-Wallis: Distribuição por Setor

Tem como objetivo verificar se as diferenças de performance ESG entre setores observadas na análise descritiva são estatisticamente significativas.

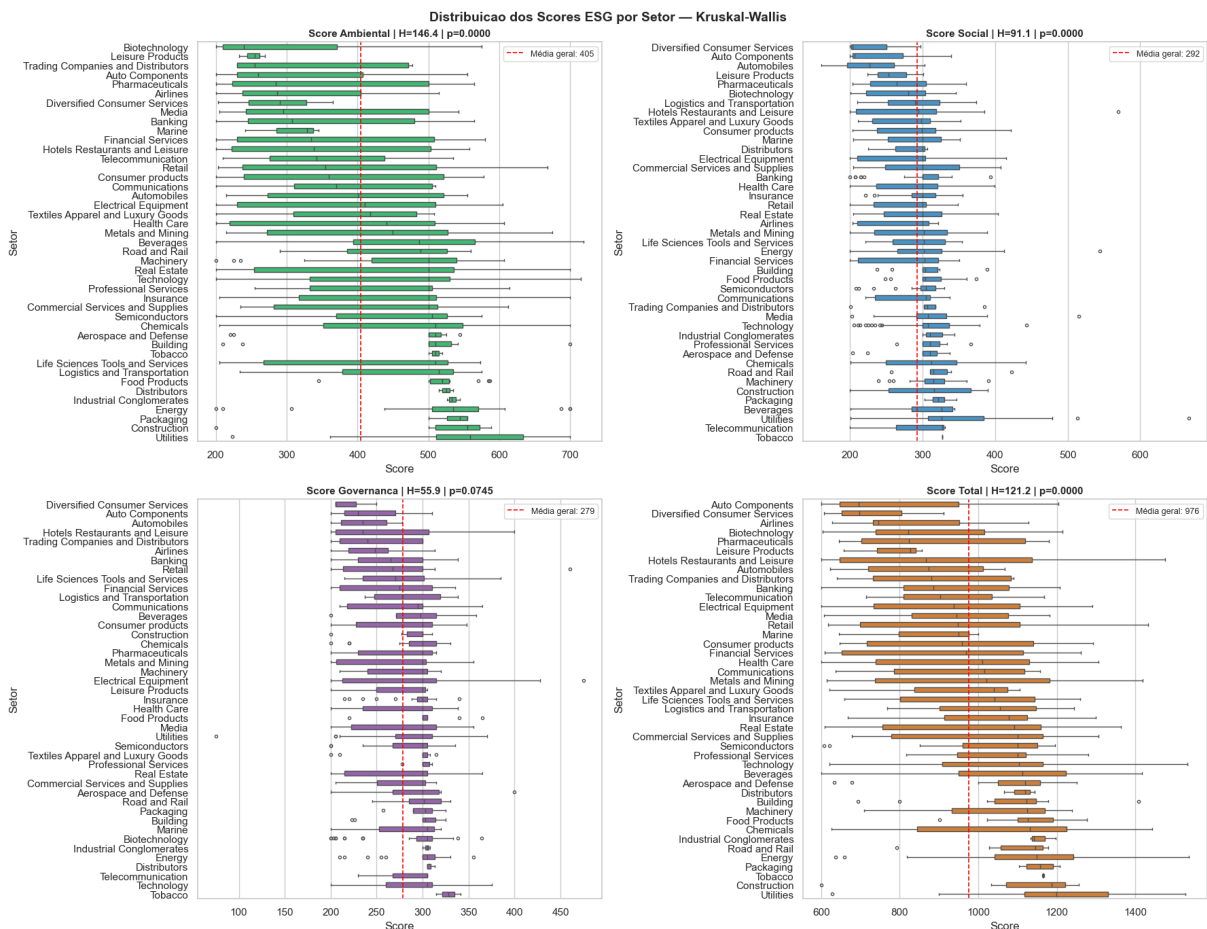


Figura 8 - Distribuição do score por Setor

- *Score Ambiental* ($H=146.4$, $p \approx 0.000$):
 - Diferença altamente significativa
 - A maior Estatística H de todas as dimensões, o que significa que setores diferem entre si em performance ambiental mais do que em qualquer outra dimensão
 - Para a dimensão ambiental, o setor é um forte preditor do score
- *Score Social* ($H=91.1$, $p \approx 0.000$):
 - Diferença significativa
 - Há diferenças entre setores, porém menos pronunciadas que no ambiental
- *Score Governança* ($H=55.9$, $p=0.075$):
 - Sem diferença significativa
 - Único caso onde $p > 0.05$, não rejeitamos H_0
 - Pode-se supor inicialmente que as diferenças de governança entre setores podem ser explicadas então pelo acaso, não havendo indícios de correlação, ou seja, o setor da empresa não determina sua performance em governança
- *Score Total* ($H=121.2$, $p \approx 0.000$):
 - Diferença significativa
 - Resultado esperado devido a influência do ambiental e social

- Conclusão:

- O setor é um preditor válido para as dimensões ambiental e social, e por consequência, total. Porém não para governança.
- Na construção da matriz de criticidade de fornecedores, o setor pode ser considerado como fator de risco para E e S, mas não como determinante isolado de G.

3.8. Principais achados da EDA

- Sobre a estrutura dos dados:

- O dataset é composto por 722 empresas, sem duplicatas e com as pontuações de ESG 100% completos
- *grades* e *levels* são complementares, não redundantes. Definem junto uma margem de *score*, mas não o seu valor absoluto.
- O *total_score* é sempre igual à soma dos três scores parciais, consistência aritmética confirmada;

- Comportamento e influência de cada dimensão:

- O score ambiental é a dimensão mais discriminante e a principal determinante do score total ($\rho = 0,94$);
- O score ambiental apresenta bimodalidade — há dois grupos estruturalmente distintos de empresas: alta e baixa performance ambiental;
- Governança é a dimensão mais homogênea e menos influenciada pelo setor de atuação;
- Todos os scores rejeitam normalidade (Shapiro-Wilk, $p \approx 0$) — testes não paramétricos são obrigatórios.

- Comportamento e influência do setor:

- O setor é um preditor estatisticamente significativo para ambiental, social e total — mas não para governança;
- Utilities lidera em todas as dimensões; Diversified Consumer Services e Leisure Products são retardatários consistentes;
- Setores industriais pesados (Packaging, Industrial Conglomerates) surpreendem positivamente — reflexo de maior pressão regulatória;
- Tobacco apresenta alta performance em governança — setor historicamente pressionado por transparência corporativa.

- Demais considerações:

- CMS Energy Corp: outlier superior em Social e inferior em Governança simultaneamente — candidata prioritária à análise na matriz de criticidade;
- No atributo *currency*, verificou-se que a maioria absoluta (97,5%) das empresas estão alocadas em dólar americano (USD), e com apenas uma empresa brasileira (BRL), a Afya Ltd e uma Suíça (CHF) a AC Immune SA. Assim, este atributo não será considerado com *feature* para o modelo.

3.8.1. Features

Após conclusões da Análise Exploratória dos Dados (EDA), concluiu-se que as melhores *features* a serem usadas para treinar todos os modelos, em ambas as tarefas de Regressão e Classificação serão:

Tabela 18 - Features a serem utilizadas e breve descrição

Atributo	Descrição
exchange	Bolsa de valores (NYSE ou NASDAQ)
industry	Setor de atuação
revenue_M	Faturamento anual em milhões USD (oriundo do dataset auxiliar)
employees	Número de funcionários (oriundo do dataset auxiliar)
environment_grade	Nota ESG ambiental (C até AAA)
social_grade	Nota ESG social (C até AAA)
governance_grade	Nota ESG de governança (C até AAA)

3.9. Modelagem

3.9.1. Split Hold-Out

- Percentuais treino/teste: Será de 70/30, conforme pressuposto da sessão 2, uma vez que o dataset principal possui 722 linhas.
- Desbalanceamento: A EDA revelou que ~70% dos dados são classe "Medium". Por isso será usado *stratify=y_clf*, assim garante-se que a proporção das três classes de risco seja mantida tanto no treino quanto no teste. Sem isso, a classe "Baixo Risco" (23% do dataset) poderia estar sub-representada em alguma fatia.
- Reprodutibilidade: Usado *random_state=42* para reprodutibilidade (exigência do projeto).
- Data leakage: Para evitar data leakage, todo o pré-processamento para treinar o modelo (encoding ordinal, one-hot e normalização) foi encapsulado dentro de um Pipeline do *scikit-learn* integrado ao *GridSearchCV*, garantindo que os transformadores fossem ajustados exclusivamente nos dados de treino e apenas aplicados nos dados de teste, nunca o contrário. O *train_test_split* foi executado nos dados brutos antes de qualquer transformação (revisando: *split 70/30* e *random_state=42* para reprodutibilidade), e a busca de hiperparâmetros ocorreu inteiramente dentro do conjunto de treino via validação cruzada. O conjunto de teste foi utilizado uma única vez, apenas na avaliação final.

3.9.2. Modelos de Regressão

3.9.2.1. KNN Regressor

O KNN foi escolhido como modelo de referência (baseline) por sua simplicidade e interpretabilidade. Na regressão é calculada a **média do total_score** dos K vizinhos mais próximos para previsão. Foi aplicado o StandardScaler para a normalização, via Pipeline antes.

Grade de hiperparâmetros (a mesma da classificação):

Tabela 19 - Tabela de hiperparâmetros para KNN (Regressão)

Hiperparâmetro	Valores a testar	Significado
n_neighbors	3, 5, 7, 9	Quantos vizinhos consultar
weights	uniform, distance	Peso igual ou proporcional à distância
metric	euclidean, manhattan	Fórmula de cálculo da distância

Total de combinações testadas: $4 \times 2 \times 2 = 16$ combinações. São poucas combinações e não se justifica utilizar Random Search. Grid Search é o método mais adequado visto que o espaço de busca é pequeno.

| MAE= 29.17 | RMSE= 41.85 | $R^2=0.9179$
Melhores params: {'model metric': 'euclidean', 'model n_neighbors': 9, 'model weights': 'distance'}

Figura 9 - Melhores parâmetros encontrados para KNN Regressor e respectivas métricas de escolha.

3.9.2.2. Árvore de Decisão (Decision Tree)

A Árvore de Decisão foi escolhida por sua alta interpretabilidade, por representar regras de negócio explícitas e legíveis através de perguntas com resultados binários. Tem o risco de overfitting, por isto, escolhidos os hiperparâmetros “clássicos” desta. Para a regressão, produz previsões numéricas pelo score médio das empresas na mesma folha.

Grade de hiperparâmetros:

Tabela 20- Tabela de hiperparâmetros para Árvore de Decisão (Regressão)

Hiperparâmetro	Valores a testar	Significado
max_depth	3, 5, 7, 10, None	Profundidade máxima da árvore
min_samples_split	2, 5, 10	Mínimo de amostras para corte
min_samples_leaf	1, 2, 4	Mínimo de amostras por folha

⇒ Não usado o hiperparâmetro criterion pois a regressão usa MSE por padrão.

Total de combinações testadas: $5 \times 3 \times 3 = 45$ combinações=> Grid Search.

| MAE= 22.81 | RMSE= 27.89 | $R^2=0.9635$
Melhores params: {'model__max_depth': 3, 'model__min_samples_leaf': 4, 'model__min_samples_split': 2}

Figura 10 - Melhores parâmetros encontrados para Árvore de Decisão e respectivas métricas de escolha.

3.9.2.3. Random Forest

O Random Forest Regressor costuma ser um ótimo candidato para regressão. Para regressão, o ensemble calcula a média das previsões de várias árvores independentes, produzindo estimativas mais suaves e precisas do que uma única árvore.

Grade de hiperparâmetros (a mesma da classificação):

Tabela 21 - Tabela de hiperparâmetros para Random Forest (Regressão)

Hiperparâmetro	Valores a testar	Significado
n_estimators	50, 100, 200	Número de árvores no ensemble (votação)
max_depth	5, 10, None	Profundidade máxima de cada árvore
min_samples_leaf	2, 5	Mínimo de amostras por folha

Total de combinações testadas: $3 \times 3 \times 2 = 18$ combinações $\Rightarrow$ Grid Search.

| MAE= 22.59 | RMSE= 27.69 | R²=0.9641
Melhores params: {'model__max_depth': 5, 'model__min_samples_split': 2, 'model__n_estimators': 200}

Figura 11 - Melhores parâmetros encontrados para Random Forest e respectivas métricas de escolha.

3.9.3. Modelos de Classificação

3.9.3.1. KNN (K-Nearest Neighbors)

Motivo da escolha pelo mesmo raciocínio do regressor: simplicidade e interpretabilidade. Na regressão é calculada a média do total_score dos K vizinhos mais próximos para previsão. Foi aplicado o StandardScaler para a normalização, via Pipeline antes.

Grade de hiperparâmetros:

Tabela 22 - Tabela de hiperparâmetros para KNN (Classificação)

Hiperparâmetro	Valores a testar	Significado
n_neighbors	3, 5, 7, 9	Quantos vizinhos consultar
weights	uniform, distance	Peso igual ou proporcional à distância
metric	euclidean, manhattan	Fórmula de cálculo da distância

Total de combinações a serem testadas: $4 \times 2 \times 2 = 16$ combinações $\Rightarrow$ Grid Search.

KNN

F1-Macro=0.7114 | Recall-Alto=0.9753 | Acc=0.7558

Melhores params: {'model__metric': 'manhattan', 'model__n_neighbors': 3, 'model__weights': 'distance'}

Relatório:

	precision	recall	f1-score	support
Alto Risco	0.96	0.98	0.97	81
Risco Moderado	0.53	0.40	0.45	50
Baixo Risco	0.67	0.76	0.71	86
accuracy			0.76	217
macro avg	0.72	0.71	0.71	217
weighted avg	0.75	0.76	0.75	217

Figura 12 - Melhores parâmetros encontrados para KNN Classificador e respectivas métricas de escolha.

3.9.3.2. Árvore de Decisão

Justificativa segue a mesma para a Regressão.

Grade de hiperparâmetros:

Tabela 23 - Tabela de hiperparâmetros para Árvore de Decisão (Classificação)

Hiperparâmetro	Valores a testar	Significado
max_depth	3, 5, 7, 10, None	Profundidade máxima da árvore
min_samples_split	2, 5, 10	Mínimo de amostras para corte
min_samples_leaf	1, 2, 4	Mínimo de amostras por folha
criterion	gini	Critério de pureza para os cortes

Total de combinações testadas: $5 \times 3 \times 2 \times 1 = 30$ combinações => Grid Search.

Decision Tree				
F1-Macro=0.7928 Recall-Alto=0.9877 Acc=0.8157				
Melhores params: {'model__max_depth': None, 'model__min_samples_leaf': 4, 'model__min_samples_split': 2}				
Relatório:				
	precision	recall	f1-score	support
Alto Risco	0.96	0.99	0.98	81
Risco Moderado	0.63	0.64	0.63	50
Baixo Risco	0.78	0.76	0.77	86
accuracy			0.82	217
macro avg	0.79	0.79	0.79	217
weighted avg	0.81	0.82	0.82	217

Figura 13 - Melhores parâmetros encontrados para Árvore de Classificação e respectivas métricas de escolha.

3.9.3.3. Random Forest

Foi escolhido por ser conhecido tradicionalmente com o modelo mais robusto dentre o conjunto dos três apresentados.

Grade de hiperparâmetros:

Tabela 24 - Tabela de hiperparâmetros para Random Forest (Classificação)

Hiperparâmetro	Valores a testar	Significado
n_estimators	50, 100, 200	Número de árvores no ensemble (votação)
max_depth	5, 10, None	Profundidade máxima de cada árvore
min_samples_split	2, 5	Mínimo de amostras para corte

Total de combinações testadas: $3 \times 3 \times 2 = 18$ combinações => Grid Search.

Random Forest				
F1-Macro=0.7901 Recall-Alto=0.9506 Acc=0.8018				
Melhores params: {'model__max_depth': 10, 'model__min_samples_split': 5, 'model__n_estimators': 100}				
Relatório:				
	precision	recall	f1-score	support
Alto Risco	0.97	0.95	0.96	81
Risco Moderado	0.60	0.78	0.68	50
Baixo Risco	0.79	0.67	0.73	86
accuracy			0.80	217
macro avg	0.79	0.80	0.79	217
weighted avg	0.82	0.80	0.80	217

Figura 14 - Melhores parâmetros encontrados para Random Forest e respectivas métricas de escolha.

4. Resultados e Discussão

Os experimentos foram rastreados pelo MLflow, possibilitando a análise, comparação e escolha dos melhores modelos.

4.1. Resultados dos Experimentos e Comparação entre Modelos




Figura 15 - Comparação entre modelos de Regressão.

REGRESSÃO – Comparação de métricas no conjunto de teste				
Target	Modelo	MAE	RMSE	R²
environment_score	KNN	29.17	41.85	0.9179
environment_score	Decision Tree	22.81	27.89	0.9635
environment_score	Random Forest	22.59	27.69	0.9641
social_score	KNN	27.05	42.21	0.5819
social_score	Decision Tree	22.68	30.49	0.7819
social_score	Random Forest	22.33	29.97	0.7892
governance_score	KNN	19.88	32.16	0.5619
governance_score	Decision Tree	16.70	24.62	0.7433
governance_score	Random Forest	16.11	24.00	0.7560
CLASSIFICAÇÃO – Comparação de métricas no teste				
Modelo	F1-Macro	Recall-Alto	Acurácia	
KNN	0.7114	0.9753	0.7558	
Decision Tree	0.7928	0.9877	0.8157	
Random Forest	0.7901	0.9506	0.8018	

Figura 16 - Principais métricas de compração entre os modelos.

Matrizes de Confusão — Classificação risk_level




Figura 17 - Matriz de confusão para comparação entres modelos de classificação.




Figura 18 - Resumo dos resultados encontrados

4.2. Discussão dos Resultados Modelo selecionado para Deploy

• Regressão:

- Environment_score foi o mais fácil de prever ($R^2 \approx 0.96$ com Random Forest e Decision Tree), o que faz sentido: a EDA mostrou que o environment_grade define a faixa do score com precisão de ± 100 pontos, e o modelo aprendeu essa correspondência com eficiência.
- Social_score e governance_score obtiveram $R^2 \approx 0.79$ e 0.75 respectivamente. A maior dificuldade reflete o achado da EDA: o setor tem correlação significativa com ambiental e social, mas não com governança (Kruskal-Wallis, $p=0.075$). O Random Forest foi vencedor nas três dimensões.
- O GridSearchCV com KFold controla o overfitting. A comparação entre o MAE de validação cruzada e o MAE de teste mostrou diferenças pequenas, indicando boa generalização e sem overfitting.

• Classificação:

- A Decision Tree foi marginalmente superior ao Random Forest em F1-Macro (0.7928 vs 0.7910), com o melhor Recall para a classe "Alto Risco" (0.9877). Isso é especialmente relevante: para gestão de risco, falsos negativos são críticos e classificar uma empresa de alto risco como moderada é pior do que o erro inverso.
- A acurácia simples seria enganosa aqui? Sim, mas menos do que esperávamos. Com a distribuição mais equilibrada do risk_level (37.5%, 39.5%, 23%), a diferença entre acurácia e F1-Macro foi pequena. O StratifiedKFold e o class_weight='balanced' garantiram atenção adequada ao "Baixo Risco".

Em resumo, para a tarefa de Regressão, o melhor modelo e que será usado para deploy será o Random Forest, já para a tarefa de Classificação, Árvore de Decisão.

Tabela 25 - Modelos vencedores para respectivas tarefas

Tarefa	Modelo	Justificativa
Regressão (E, S, G)	Random Forest	Menor MAE/RMSE e maior R^2 nas três dimensões

Classificação (risk_level)	Decision Tree	Maior F1-Macro e Recall-Alto-Risco; mais interpretável para BI
-------------------------------	---------------	---

Salvo os artefatos e modelos via MLflow: Target Modelo run_id Métrica
environment_score Random Forest e111bfbf50d34ebab7b5edd7436c982b $R^2=0.964$
social_score Random Forest d54e13c37eda4bd98eb878e4bb71cff1 $R^2=0.789$
governance_score Random Forest 7244cee29e47420aa5add480f66867a7 $R^2=0.756$

5. Limitações do Trabalho

A maior limitação para este trabalho foi a ausência de amostras *total_level* nas classes Excellent e Low, o que permitiria criar um aprendizado mais amplo, dentro de toda a faixa de pontuação total. Assim como, poucos atributos que permitissem uma busca mais precisa do valor da pontuação de cada dimensão, o que levou a buscar atributos externos de faturamento e quantidade de funcionários. A falta de atributos que refletissem diretamente na pontuação e uma população não muito grande de dados e de forma desequilibrada, pode explicar o fato de os modelos conseguirem um resultado de alta precisão, apesar dos resultados obtidos serem satisfatórios e capazes de cumprir os objetivos deste trabalho com sucesso.

6. Conclusões e Trabalhos Futuros

6.1. Conclusões

Este projeto demonstrou que é possível construir uma solução completa e reproduzível de Machine Learning aplicada à gestão de risco ESG de fornecedores, cobrindo todo o ciclo de vida de um projeto de ciência de dados, desde a ingestão de dados brutos com rastreabilidade por hash MD5 até a entrega de um dashboard interativo containerizado com Docker. A adoção da arquitetura medalhão (Bronze → Silver → Gold) garantiu um pipeline de dados limpo, auditável e preparado para consumo pelos modelos de machine learning, enquanto o rastreamento de experimentos com MLflow assegurou a reprodutibilidade e comparabilidade entre KNN, Árvore de Decisão e Random Forest. A EDA revelou que o score ambiental é o principal determinante do risco ESG total (correlação de 0,944), que o dataset apresenta forte desbalanceamento de classes — com predominância da categoria "Medium", e que o setor de atuação é um preditor válido para as dimensões Ambiental e Social, mas não para Governança, achados que orientaram diretamente as escolhas metodológicas de validação cruzada estratificada e uso do F1-score ponderado como métrica principal, em detrimento da acurácia.

6.2. Trabalhos Futuros

Do ponto de vista técnico, os principais caminhos de evolução para este projeto envolvem, em primeiro lugar, a integração com um banco de dados relacional MySQL, permitindo que o dashboard Streamlit execute operações de inserção, edição e consulta diretamente sobre as tabelas de fornecedores, tornando a solução operacionalmente viável em um ambiente corporativo real. Em segundo lugar, seria de grande valor a incorporação de modelos mais sofisticados, como Gradient Boosting (XGBoost ou LightGBM) e redes neurais simples para avaliar se há ganho expressivo de desempenho sobre o Random Forest, especialmente nas classes minoritárias de risco alto e baixo. Por fim, do ponto de

vista do negócio, a solução poderia evoluir para receber dados reais de fornecedores do cliente via formulário ou API, substituindo o dataset público do Kaggle por uma base proprietária e periodicamente atualizada, transformando o projeto acadêmico em um produto de gestão ESG efetivamente operacional.

7. Referências

- GÉRON, A. Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol: O'Reilly Media, 2019.
- GUIDO, S.; MÜLLER, A. C. Introduction to Machine Learning with Python: A Guide for Data Scientists. Sebastopol: O'Reilly Media, 2016.
- DUDA, R. O.; HART, P. E.; STORK, D. G. Pattern Classification. 2. ed. New York: Wiley, 2001.
- KING, A. Public Company ESG Ratings Dataset. Kaggle, 2022. Disponível em: <https://www.kaggle.com/datasets/alistairking/public-company-esg-ratings-dataset>. Acesso em: 26 mai. 2026.
- MLFLOW. MLflow: A Machine Learning Lifecycle Platform. Disponível em: <https://mlflow.org>. Acesso em: 10 jun. 2026.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.
- STREAMLIT INC. Streamlit: The fastest way to build data apps. Disponível em: <https://streamlit.io>. Acesso em: 10 jun. 2026.
- DOCKER INC. Docker: Accelerated Container Application Development. Disponível em: <https://www.docker.com>. Acesso em: 10 jun. 2026.