



Projeto ML I - Relatório

Descrição: Relatório apresentando a análise exploratória de dados (EDA), estatísticas descritivas, tratamento inicial dos dados e visualizações analíticas do dataset selecionado.

1. Introdução

1.1. Contextualização

O presente relatório documenta a Entrega 2 do projeto de Machine Learning I, desenvolvido pelo grupo NorthData Consulting no âmbito da disciplina de Machine Learning I da CESAR School.

Problema abordado

O problema central é a gestão de risco ESG (Environmental, Social and Governance) em cadeias de suprimentos corporativas. Especificamente, o projeto visa apoiar a EdenRed na avaliação e classificação de fornecedores segundo seu nível de maturidade e risco em práticas de sustentabilidade e governança.

Sem uma metodologia estruturada, empresas como a EdenRed dependem de avaliações manuais e subjetivas de fornecedores — processo lento, custoso e sujeito a vieses. A aplicação de Machine Learning sobre dados ESG públicos permite automatizar e escalar essa avaliação, tornando-a mais consistente e auditável.

Objetivo da solução

Desenvolver uma solução completa de Machine Learning que classifique empresas públicas segundo seu perfil de risco ESG, gerando três entregas fundamentais para o negócio:

Matriz de criticidade dos fornecedores — classificação cruzando impacto ambiental/social com probabilidade de não conformidade;

Mapa de riscos ESG com plano de ação — identificação de ameaças por categoria e sugestão de planos personalizados;

Painel de Scorecards, KPIs, Ranking e Benchmarking — dashboard interativo com métricas de desempenho ESG.

Domínio da aplicação

O dataset utilizado é o Public Company ESG Ratings, disponível no Kaggle, contendo avaliações ESG de 722 empresas públicas negociadas em bolsas de valores, com dados coletados entre

abril e novembro de 2022. As avaliações cobrem três dimensões — ambiental, social e governança — expressas em scores numéricos, grades (A, AA, B, BB, BBB, C) e níveis qualitativos (Excellent, High, Medium, Low).

Importância da análise exploratória

A EDA é a etapa mais crítica do pipeline de Machine Learning — é onde se decide se o dado é confiável o suficiente para sustentar um modelo. No contexto de risco ESG, um modelo treinado sobre dados inconsistentes ou mal compreendidos pode classificar fornecedores de alto risco como seguros, com consequências reputacionais e regulatórias graves para a EdenRed.

Neste projeto, a EDA revelou achados que impactam diretamente as decisões de modelagem: bimodalidade no score ambiental, inconsistências nos nomes de setores, presença de SPACs sem classificação setorial e a estrutura redundante entre scores, grades e levels — todos tratados antes de qualquer modelagem.

2. Inspeção dos Dados

2.1. Carregamento e organização

Os dados foram carregados seguindo a arquitetura Medalhão, com separação clara entre as camadas de dados brutos (Bronze), tratados (Silver). O script de ingestão `src/ingest_data.py` realiza o download automático do dataset via API do Kaggle, calcula o hash MD5 do arquivo para garantia de integridade e registra os metadados de ingestão em um arquivo JSON na camada Bronze.

Bibliotecas utilizadas

Biblioteca	Versão	Finalidade
pandas	2.x	Manipulação e análise de dados tabulares
numpy	1.x	Operações numéricas e vetoriais
matplotlib	3.x	Geração de visualizações estáticas
seaborn	0.13.x	Visualizações estatísticas de alto nível
scipy	1.x	Testes estatísticos (Shapiro-Wilk, Kruskal-Wallis, Spearman)
yfinance	0.2.x	Enriquecimento de dados via API do Yahoo Finance
kaggle	1.x	Download automatizado do dataset via API

2.2. Organização Inicial do Notebook

O notebook está organizado em seis sessões:

1. Preparação do Ambiente
2. Leitura da Base de Dados
3. Visão Geral do Dataset
4. Qualidade dos Dados
5. Estatísticas Descritivas
6. Tratamento dos Dados

2.3. Análise de qualidade dos dados

Valores ausentes

A análise de valores ausentes revelou que as colunas críticas para modelagem – scores, grades e levels – estão 100% completas. Os nulos identificados concentram-se em colunas auxiliares:

Coluna	Nulos	% do Total	Impacto
logo	20	2,77%	Nenhum – descartada
weblink	16	2,22%	Nenhum – descartada
industry	13	1,80%	Moderado – tratado via API
Demais colunas	0	0,00%	Nenhum

Duplicatas

Nenhuma linha completamente duplicada foi identificada. A verificação de duplicidade por ticker e por name também confirmou que cada empresa aparece uma única vez no dataset.

Consistência do total_score

Verificou-se que o campo total_score é consistente com a soma de environment_score, social_score e governance_score em todos os 722 registros, confirmando a integridade aritmética do dado.

Inconsistências em variáveis categóricas

Foram identificadas 4 inconsistências na coluna industry, onde o mesmo setor aparecia com grafias diferentes:

Nome original	Nome padronizado	Registros afetados
Aerospace & Defense	Aerospace and Defense	1

Nome original	Nome padronizado	Registros afetados
Energy (com espaço)	Energy	2
Hotels, Restaurants & Leisure	Hotels Restaurants and Leisure	Verificado
Metals & Mining	Metals and Mining	1

A correção foi aplicada definitivamente na camada Silver através do script `src/silver_transform.py`, reduzindo de 47 para 43 setores únicos.

Redundância entre grades e levels

A análise de correspondência revelou que grades e levels não são completamente redundantes entre si — um mesmo level pode corresponder a mais de um grade. Por exemplo, tanto o grade A quanto o grade BBB correspondem ao level High, porém em faixas de score distintas e não sobrepostas. Ambas as colunas foram mantidas por serem complementares e pelo baixo custo computacional do dataset.

3. Estatísticas Descritivas

3.1. Tendência central e dispersão dos scores ESG

Dimensão	Média	Mediana	Desvio Padrão	Mínimo	Máximo	CV (%)
Ambiental	405	483	155	200	719	38,3%
Social	292	302	81	75	667	27,7%
Governança	279	300	57	75	475	20,5%
Total	976	1.046	237	583	1.500	24,3%

Score Ambiental: maior dispersão de todas as dimensões (CV = 38,3%). A diferença expressiva entre média (405) e mediana (483) indica assimetria negativa – um grupo de empresas com baixa performance ambiental puxa a média para baixo. É a dimensão mais discriminante entre empresas.

Score Social: dispersão moderada (CV = 27,7%). Média e mediana mais próximas indicam distribuição mais simétrica. Presença de 7 outliers superiores – empresas com desempenho social excepcionalmente alto.

Score Governança: menor dispersão de todas (CV = 20,5%). Empresas convergem fortemente em governança – o setor de atuação não determina significativamente essa dimensão, conforme confirmado pelo teste de Kruskal-Wallis.

3.2. Quartis e detecção de outliers

Dimensão	Q1 (P25)	Mediana	Q3 (P75)	IQR	Lim. Inf.	Lim. Sup.
Ambiental	240	483	519	279	-178*	937
Social	243	302	323	80	123	442
Governança	235	300	310	75	123	423
Total	763	1.046	1.144	381	192	1.716

* Limite inferior negativo no score ambiental é matematicamente possível pelo método IQR, mas impossível na prática. Indica distribuição bimodal, onde o IQR sozinho é insuficiente para detectar outliers nessa dimensão.

Foram identificados 11 registros de outliers em 10 empresas distintas, todos nas dimensões Social e Governança. A CMS Energy Corp é a única empresa outlier em duas dimensões simultaneamente – outlier superior em Social (score 667) e outlier inferior em Governança (score 75), revelando performance ESG extremamente assimétrica entre dimensões.

4. Tratamento dos Dados – Camada Silver

Todas as transformações foram aplicadas de forma centralizada no script `src/silver_transform.py`, respeitando o princípio da arquitetura Medalhão: o dado bruto da camada Bronze permanece intocável; todas as transformações ocorrem exclusivamente na camada Silver.

#	Tratamento	Decisão	Justificativa
1	Remoção de colunas	Descartadas: logo, weblink, currency, exchange	Sem valor preditivo para modelagem ou dashboard ESG
2	Normalização de nomes	47 → 43 setores únicos após padronização	Inconsistências identificadas na EDA (seção 4 do notebook)
3	Preenchimento de nulos em industry	4 preenchidos via yfinance; 9 imputados como 'Unknown'	SPACs já dissolvidas não encontradas na API – imputação conservadora
4	Conversão de tipo	last_processing_date: str → datetime (formato %d-%m-%Y)	Formato identificado na EDA; necessário para operações temporais futuras
5	Grades e levels	Mantidos todos – scores, grades e levels por dimensão	Dataset pequeno; decisão de uso postergada para a camada Gold e pipeline de ML

O resultado da transformação reduziu o dataset de 21 para 17 colunas, mantendo 722 linhas – sem perda de registros. Os metadados da transformação foram registrados em `data/silver/metadata_silver.json`, incluindo hash MD5, data de processamento e lista de etapas aplicadas.

5. Análise Exploratória e Visualizações


A EDA foi estruturada em duas frentes: análise descritiva (o que os dados mostram) e análise inferencial (o que os dados sugerem com significância estatística). As visualizações abaixo sintetizam os principais achados.

5.1 Tendência Central e Dispersão dos Scores ESG

Objetivo

Comparar a distribuição dos scores nas três dimensões ESG e no score total, identificando onde as empresas se concentram e quão heterogêneas são entre si.

Gráfico



Interpretação

- Score Ambiental
 - Tem a maior dispersão de todos, com pontos espalhados de 200 a 700+
 - Média (405) abaixo da mediana (~480), demonstrando distribuição assimétrica à esquerda, puxada por empresas com baixa performance ambiental
 - Esta se mostra como a dimensão onde as empresas mais se diferenciam entre si
- Score Social
 - Distribuição mais concentrada e simétrica, com média e mediana bem próximas (~292 e ~300)
 - Há poucos outliers extremos
 - Logo, empresas tendem a convergir em performance social
- Score Governança
 - Demonstra a menor amplitude de todas as dimensões

- Ou seja, caixa compacta com empresas com comportamento mais homogêneo em governança

- Média (279) ligeiramente abaixo da mediana (~295)

- Score Total

- Reflete a soma dos três, portanto, dispersão moderada

- Média (976) abaixo da mediana (~1030), assimetria puxada pelo score ambiental

- Outliers superiores bem visíveis, havendo empresas excepcionalmente bem avaliadas

- Conclusão


O score ambiental demonstra ser o fator principal de diferenciação entre empresas. Já a Governança é onde há mais homogeneidade. O que sugere que os modelos de classificação terão no score ambiental sua feature mais discriminante.

5.2 Distribuição Real vs Curva Normal Teórica

Objetivo

Confirmar visualmente a não normalidade dos scores, complementando os resultados do teste de Shapiro-Wilk.

Gráfico



Interpretação


Todas as dimensões ESG apresentam p-valor < 0.05, rejeitando a hipótese nula de normalidade em todas elas.

5.3 Matriz de Correlação de Spearman

Objetivo

Medir a força e direção das relações entre as dimensões ESG, identificando quais dimensões são mais interdependentes.

Gráfico



Interpretação

- Todos os pares apresentaram correlação positiva e estatisticamente significativa (p-valor ≈ 0), confirmando que as três dimensões ESG estão interligadas.


- Ambiental $\times$ Social (rho = 0.703) => Correlação forte
 - É o par mais correlacionado entre as dimensões independentes
 - Demonstra-se que empresas com boas práticas ambientais tendem fortemente a ter boas práticas sociais, supõe-se que possa haver uma cultura ESG integrada
- Ambiental $\times$ Governança (rho = 0.562) => Correlação moderada
 - Pode-se supor que governança é mais influenciada por pressão regulatória e estrutura societária do que por cultura ESG, o que explica a correlação menor
- Social $\times$ Governança (rho = 0.579) => Correlação moderada
 - Comportamento similar ao par Ambiental $\times$ Governança
 - Governança é a dimensão mais "independente" das três
- Correlações com o Total:
 - Ambiental $\times$ Total (0.944): altíssima. O score ambiental é o principal determinante do score total.
 - Social $\times$ Total (0.824): forte. É a segunda dimensão mais determinante
 - Governança $\times$ Total (0.714): forte. Porém a menos determinante das três

5.4 Média dos Scores ESG por Setor

Objetivo

Identificar quais setores lideram e quais ficam abaixo da média geral em cada dimensão ESG, gerando insumo direto para a matriz de criticidade de fornecedores.

Gráfico



Interpretação

- Desempenho em total score

- Setores de Utilidades, Tabaco e Conclomerado Industriais, respectivamente nas primeiras três posições.
- Setores de Serviços de Consumo Diversos, Produtos de Lazer e Linhas aéreas, respectivamente nas últimas três posições.

- *<u>Dimensão Ambiental com maior variação


- Conforme já levantado anteriormente no gráfico de boxplo*, a área ambiental possui a maior variação, onde o líder Utilidades têm score de 550, enquanto a última posição Produtos de Lazer com score de 252, mais que a metade.

5.5 - Quartis e Outliers por Dimensão ESG

Objetivo

Identificar empresas com comportamento anômalo em relação ao grupo, candidatas a análise aprofundada na matriz de criticidade.

Gráfico



Interpretação

- Score Ambiental
 - Nenhum outlier detectado
 - Possui a maior amplitude entre as dimensões, demonstrando haver empresas com alta e baixa performance
 - Limite inferior negativo (aprox. -200) sinalizando que o método IQR sozinho é insuficiente avaliar para esta dimensão
- Score Social
 - 7 outliers superiores²
- Score Governança
 - 3 outliers superiores
 - 1 outlier inferior²
- Score total
 - Nenhum outlier


² **CMS Energy Corp:** Demonstrou ter uma performance assimétrica, sendo um outlier superior para a dimensão Social, porém, também sendo um outlier inferior na dimensão Governança

5.6 Kruskal-Wallis: Distribuição por Setor

Objetivo

Verificar se as diferenças de performance ESG entre setores observadas na análise descritiva são estatisticamente significativas.

Gráfico



Interpretação

- Score Ambiental (H=146.4, p≈0.000)

- Diferença altamente significativa
- A maior Estatística H de todas as dimensões, o que significa que setores diferem entre si em performance ambiental mais do que em qualquer outra dimensão
- Confirma e valida estatisticamente o que observamos visualmente na seção 5.4
- Para a dimensão ambiental, o setor é um forte preditor do score

- Score Social (H=91.1, p≈0.000)

- Diferença significativa
- Há diferenças entre setores, porém menos pronunciadas que no ambiental

- Score Governança (H=55.9, p=0.075)

- Sem diferença significativa
- Único caso onde $p > 0.05$, não rejeitamos H_0

- Pode-se supor inicialmente que as diferenças de governança entre setores podem ser explicadas então pelo acaso, não havendo indícios de correlação, ou seja, o setor da empresa não determina sua performance em governança

- Score Total ($H=121.2$, $p \approx 0.000$)

- Diferença significativa
- Resultado esperado devido a influência do ambiental e social

- **Conclusão**

- O setor é um preditor válido para as dimensões ambiental e social, e por consequência, total. Porém não para governança.
- Na construção da matriz de criticidade de fornecedores, o setor pode ser considerado como fator de risco para E e S, mas não como determinante isolado de G.

6. Principais Achados da EDA

A análise exploratória revelou os seguintes achados que orientarão diretamente as decisões de modelagem:

Sobre a estrutura dos dados

- O dataset é composto por 722 empresas, sem duplicatas e com scores 100% completos
- Grades e levels são complementares, não redundantes: o mesmo level pode corresponder a mais de um grade em faixas de score distintas;
- O total_score é sempre igual à soma dos três scores parciais, consistência aritmética confirmada;
- 13 empresas sem setor informado, sendo 9 SPACs já dissolvidas, imputadas como 'Unknown' após tentativa de enriquecimento via API.

Sobre o comportamento das dimensões

- O score ambiental é a dimensão mais discriminante e a principal determinante do score total ($\rho = 0,94$);
- O score ambiental apresenta bimodalidade – há dois grupos estruturalmente distintos de empresas: alta e baixa performance ambiental;
- Governança é a dimensão mais homogênea e menos influenciada pelo setor de atuação;
- Todos os scores rejeitam normalidade (Shapiro-Wilk, $p \approx 0$) – testes não paramétricos são obrigatórios.

Sobre o perfil setorial

- O setor é um preditor estatisticamente significativo para ambiental, social e total – mas não para governança;
- Utilities lidera em todas as dimensões; Diversified Consumer Services e Leisure Products são retardatários consistentes;
- Setores industriais pesados (Packaging, Industrial Conglomerates) surpreendem positivamente – reflexo de maior pressão regulatória;
- Tobacco apresenta alta performance em governança – setor historicamente pressionado por transparência corporativa.

Sobre outliers e casos de atenção

- CMS Energy Corp: outlier superior em Social e inferior em Governança simultaneamente – candidata prioritária à análise na matriz de criticidade;
- 9 empresas classificadas como SPACs sem setor identificável – representam risco de classificação inadequada na modelagem;
- O método IQR é insuficiente para detectar outliers no score ambiental devido à bimodalidade – recomendar Isolation Forest na modelagem.

7. Próximos Passos – Entrega 3

A Entrega 3 abrangerá a modelagem completa, validação e rastreamento de experimentos com MLflow. O planejamento a seguir é orientado diretamente pelos achados desta EDA.

7.1. Definição dos targets de modelagem

- Classificação: total_level como variável-alvo (Leader / Average / Laggard) – 3 classes;
- Regressão: total_score como variável-alvo contínua;
- Os grades e levels das dimensões individuais serão avaliados como features ou targets alternativos.

7.2. Estratégia de features

- Features primárias: environment_score, social_score, governance_score;
- Features contextuais: industry (após encoding), last_processing_date (após extração de mês);
- Atenção à multicolinearidade: scores E, S e G são correlacionados — avaliar PCA ou seleção de features;
- Evitar data leakage: não usar grades/levels como features ao prever o nível total.

7.3. Modelos a treinar

- KNN (K-Nearest Neighbors) — baseline simples;
- Árvore de Decisão — interpretabilidade para o negócio;
- Random Forest — modelo ensemble de referência;
- Modelo adicional a definir: Gradient Boosting ou SVM.

7.4. Estratégias de validação

- Holdout (70/30) como divisão base;
- Validação cruzada k-fold (k=5) para estimativa robusta de generalização;
- Leave-One-Out avaliado — dataset com 722 registros torna LOO computacionalmente viável, mas potencialmente redundante com k-fold alto;
- Grid Search / Random Search para otimização de hiperparâmetros;
- Justificativa da estratégia final será documentada no relatório da Entrega 3.

7.5. MLflow

- Registro de todos os parâmetros e métricas de cada experimento;
- Comparação entre modelos via MLflow UI;
- Salvamento do modelo final para uso no dashboard;